

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ  
РОССИЙСКОЙ ФЕДЕРАЦИИ

федеральное государственное автономное образовательное учреждение высшего  
образования «Национальный исследовательский университет ИТМО»  
(Университет ИТМО)

ОТЧЕТ  
О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

Сегментация зубов по КЛКТ-снимкам  
(этап №)

Руководитель НИР,  
Ведущий научный сотрудник, к.т.н., доцент

\_\_\_\_\_ФИО

Исполнитель  
Студент 1 курса магистратуры  
направления «Руководитель IT-разработки»

Матюшов И.В.

## СОДЕРЖАНИЕ

<b>1</b>	<b>ВВЕДЕНИЕ .....</b>	<b>3</b>
<b>2</b>	<b>МАТЕРИАЛЫ И МЕТОДЫ .....</b>	<b>4</b>
2.1.	ОПИСАНИЕ И ПРЕДОБРАБОТКА НАБОРА ДАННЫХ.....	4
2.2.	NNU-NET ФРЕЙМВОРК .....	5
<b>3</b>	<b>РЕЗУЛЬТАТЫ .....</b>	<b>7</b>
3.1.	РЕЗУЛЬТАТЫ ПРЕДСКАЗАНИЙ.....	7
3.2.	МЕТРИКИ КАЧЕСТВА СЕГМЕНТАЦИИ.....	9
<b>4</b>	<b>ОБСУЖДЕНИЕ .....</b>	<b>12</b>
<b>5</b>	<b>ЗАКЛЮЧЕНИЕ .....</b>	<b>12</b>
	<b>ССЫЛКИ .....</b>	<b>13</b>
	<b>ПРИЛОЖЕНИЯ .....</b>	<b>13</b>

# Сегментация зубов по КЛКТ-снимкам

**Аннотация.** В данной научно-исследовательской работе показан подход к решению задачи сегментации зубов пациентов с разделением на отдельные классы. Целью данного исследования стала разработка и апробирование подхода глубокого обучения с использованием фреймворка nnU-Net для многоструктурной сегментации на снимках конусно-лучевой компьютерной томографии (КЛКТ). Были описаны подход к предобработке исходных данных и результирующие метрики качества сегментации. Также показан путь возможного улучшения решения через масштабирование nnU-Net. Исходный код решения доступен в открытом доступе.

**Ключевые слова:** Конусно-лучевая компьютерная томография · nnU-Net · ToothFairy2 Dataset · Визуализация зубов · Глубокое обучение · Биомедицина · Модели нейронных сетей

## 1 Введение

Решение задачи сегментации зубов на сегодняшний день имеет жизненно-важное значение для клинической практики. Точная идентификация зубов, включая их формы и границы на двумерных (2D) и трехмерных (3D) изображениях позволяют врачам стоматологам и зубным техникам обеспечить высокую точность предиктивного выявления и диагностики заболеваний, планирования лечения, прогнозирования результатов. Также качественная сегментация для создания трехмерной модели зуба из изображений конусно-лучевой компьютерной томографии (КЛКТ) может служить основой для цифровизации стоматологических рабочих процессов. Помимо того, корректное обнаружение и сегментация зубов на КЛКТ-снимках могут быть полезны для диагностики патологий, оценки протезирования, планирования ортодонтического лечения и других клинических случаев. Также возможно проведение морфологической и позиционной визуализации зубов для содействия процессу принятия врачебных решений.

Однако решение задачи сегментации с разделением на отдельные зубы, является чрезвычайно сложным и трудоемким процессом. Стандартные традиционные методы обработки изображений для решения задачи сегментации зубов на КЛКТ-снимках являются малоэффективными и требующими вмешательства человека, по этой причине подвержены ошибкам человеческого фактора [1]. Также подходы к подгонке на основе шаблонов не дают гарантий качества сегментации многокорневых зубов. Кроме того, расплывчатые границы между корнем зуба и альвеолярным отростком и неоднородность интенсивности изображений могут привести к ложной сегментации [2]. Данные

вышеупомянутые классические подходы к сегментации требуют трудоемких ручных корректировок для достижения точной сегментации, а также являются зависимыми от оператора и неточными, особенно при наличии артефактов, связанных с материалами высокой плотности [6].

Для преодоления проблем традиционных подходов к задаче сегментации в области стоматологии стали использоваться сверточные нейронные сети (CNN). Глубокие нейронные сети, хорошо обученные сквозным методом способны превосходить в точности и трудоемкости процесса классические подходы. В области стоматологии глубокое обучение позволило обнаруживать и сегментировать зубы на основе 2D-рентгенографии, прогнозировать прорезывание новых зубов, обнаруживать и диагностировать кариес зубов. Однако исследования на тему применения глубокого обучения для сегментации зубов по КЛКТ-снимкам носят немногочисленный характер, во многом по причине отсутствия больших общедоступных наборов данных [3]. Поэтому целью научно-исследовательской работы стала разработка и апробирование подхода глубокого обучения с использованием фреймворка nnU-Net, позволяющего выполнять точную и эффективную по времени сегментацию и классификацию 3D зубов при помощи КЛКТ-снимков. Новизна данной работы состоит в использовании свежего набора данных с соревнований MICCAI 2024 ToothFairy2 challenge.

## 2 Материалы и методы

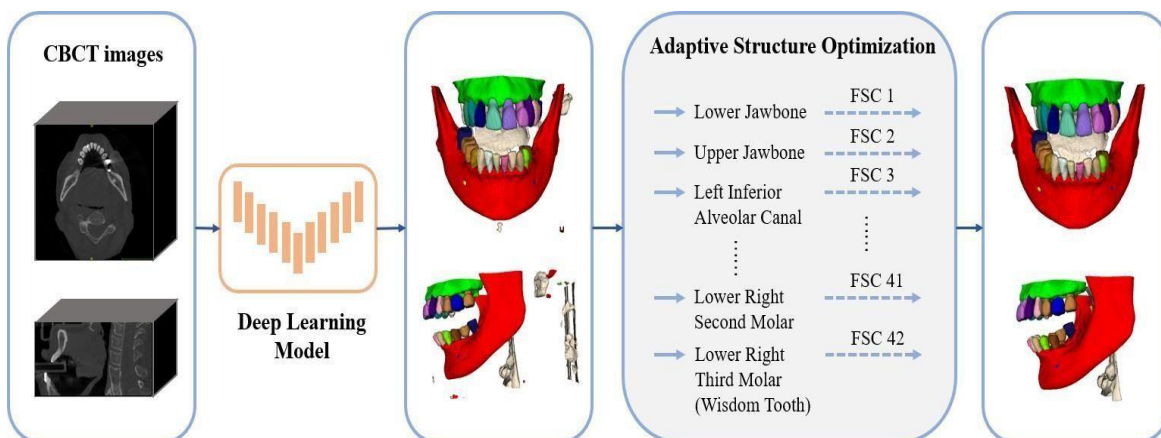


Рисунок 1 - Общая схема решения задачи сегментации по КЛКТ-снимкам

### 2.1. Описание и предобработка набора данных

Для решения поставленной задачи мультиклассовой сегментации был предоставлен набор данных, вместе с масками для изображений. Задача разметки данных была изначально решена.

Данные были получены из открытого источника для проведения соревнований по глубокому обучению ToothFairy2 Challenge. Набор данных содержал 480 аннотированных КЛКТ-снимков и столько же масок для них в .mha формате. Аннотации охватывали 42 класса, начиная от костей до альвеолярных каналов, синусов, мостов, имплантатов и отдельных зубов (согласно нотации FDI, принятой международной ассоциацией стоматологов). Полный перечень аннотаций (классов) представлен в приложении работы.

КЛКТ-снимки – это 3D изображения со следующими параметрами: шкала Хаунсфилда (шкала рентгеновской плотности), классы набора данных (42), максимальная форма объема (266, 512, 512), минимальная форма объема (170, 272, 345), медианная форма объема (169, 356, 375).

Общий набор КЛКТ-снимков был разбит на следующие подмножества: обучающий, валидационный и тестовый в пропорции 70% : 20% : 10%. Распределение КЛКТ-снимков по выборкам было случайным, однако охватывало все 42 класса зубов. Загрузка снимков в модель и создание отпечатка набора данных представлены в приложении работы. Предварительно КЛКТ-снимки вместе с масками были преобразованы удобный для работы формат. А именно исходные 42 класса были промаркированы в непрерывную числовую последовательность для задачи мультиклассовой сегментации в интервале от 0 до 42.

## **2.2. nnU-Net фреймворк**

После завершения этапа подготовки данных для модели глубокого обучения, в качестве решения задачи мультиклассовой сегментации был выбран nnU-net фреймворк.

Фреймворк nnU-Net предоставляет метод семантической сегментации, который автоматически адаптируется к заданному набору данных. Это самонастраивающийся метод для сегментации биомедицинских изображений на основе глубокого обучения. Под капотом решения реализуется U-Net архитектура нейронной сети. Решение анализирует предоставленные ему обучающие случаи и автоматически настраивает конвейер сегментации. Надежность работы данного фреймворка подтверждается успешным его использованием на соревнованиях из области биомедицины, также выдерживает конкуренцию с решениями ручной работы для каждого соответствующего набора данных (9 из 10 соревнований MICCAI 2020, 5 из 7 MICCAI 2021 команд построили свои методы на основе nnU-Net и одержали победу) [3].

Область применения решения – семантическая сегментация. Оно способно обрабатывать 2D и 3D изображения с произвольными входными модальностями/каналами. Также решение различает

расстояние между вокселями, анизотропию и является надежным даже при сильном дисбалансе классов. Решение не требовательно к большому числу обучающих случаев, в сравнении с альтернативами, в некотором смысле даже меньше по причине использования механизма аугментации (обогащения данных).

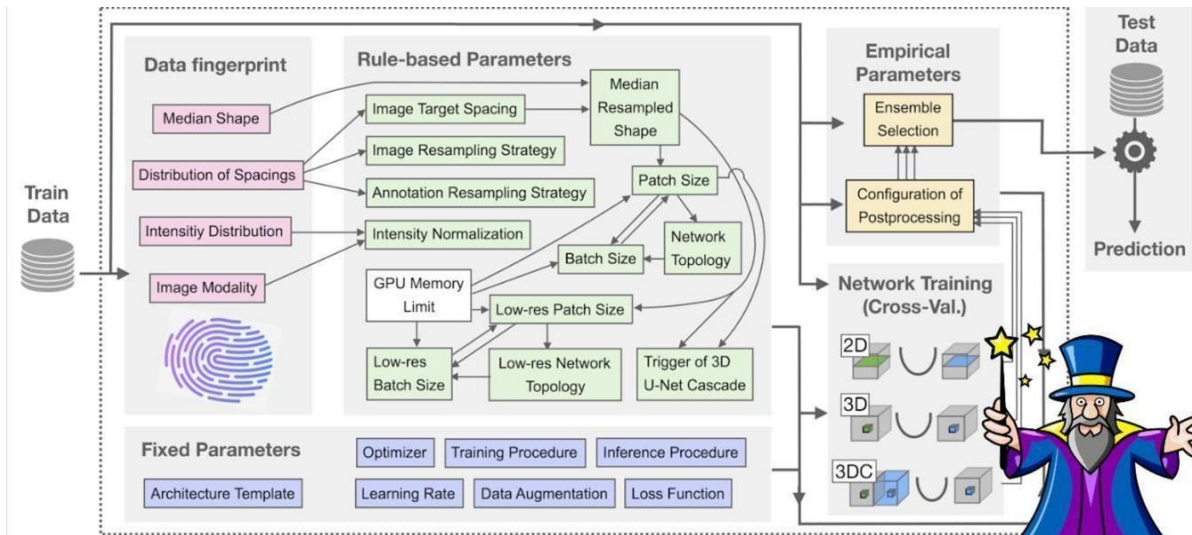


Рисунок 2 - nnU-Net архитектура решения [7]

Следует понять принцип работы системы поддержки принятия решений (СППР) nnU-Net. Получив новый набор данных на вход, nnU-Net будет систематически анализировать предоставленные обучающие случаи и по ним создавать «отпечаток набора данных / data fingerprint». Затем nnU-Net создает несколько конфигураций U-Net для каждого набора данных:

1. 2D: 2D U-Net (для 2D и 3D наборов данных)
2. 3D\_fullres: 3D U-Net, которая работает с высоким разрешением изображения (только для 3D наборов данных)
3. 3D\_lowres -> 3D\_cascade\_fullres: каскад 3D U-Net, где сначала 3D U-Net работает с изображениями низкого разрешения, а затем вторая 3D U-Net высокого разрешения уточняет прогнозы первой (только для 3D наборов данных с большими размерами изображений)

Важно обратить внимание, что не все конфигурации U-Net создаются для всех наборов данных. В наборах данных с изображениями небольшого размера каскад U-Net (и вместе с ним конфигурация 3D\_lowres) опускается, поскольку размер патча U-Net полного разрешения уже покрывает большую часть входных изображений. При работе с исходным набором данных nnU-Net инициализировал U-Net 3D\_fullres и 3D\_lowres конфигурации сети.

СППР nnU-Net настраивает свои конвейеры сегментации исходя из следующих соображений:

1. Фиксированные параметры не адаптируются. Во время разработки решения была заложена определенная надежная конфигурация (конкретная архитектура и свойства обучения), которая готова для использования. Сюда входит функция потерь nnU-Net, механизм аугментации набора данных и скорость обучения. Подбор гиперпараметров для улучшения метрик качества модели делегируется решению.
2. Параметры на основе правил используют отпечаток набора данных для адаптации определенных свойств конвейера сегментации, следуя заранее запрограммированным эвристикам. Например, топология сети (поведение пула и глубина архитектуры сети) адаптируются к размеру патча. Размер патча, топология сети и размер пакета оптимизируются совместно с учетом некоторых ограничений памяти GPU.
3. Эмпирические параметры во многом являются методом проб и ошибок. К примеру, выбор наилучшей конфигурации U-Net для заданного набора данных (2D, 3D с полным разрешением, 3D с низким разрешением, 3D каскад) и оптимизации стратегии постобработки.

Главная идея СППР nnU-Net в том, чтобы максимально адаптироваться к обучающему набору данных. Фреймворк анализирует поступающие ему на вход данные и подбирает оптимальные параметры для обучения. Сначала решение исследует входящие данные (размеры изображений, распределение значений пикселей, число классов и т. д.), после чего создает уникальный отпечаток данных. На основе отпечатка данных nnU-Net автоматически выбирает U-Net конфигурации сети (2D, 3D или 3D\_cascade). Далее настраивает гиперпараметры обучения такие как скорость обучения, размер пакета, размер патча. Выполняет нормализацию и аугментацию данных, выбирает оптимизатор (алгоритм обновления весов) и функцию потерь. После выбора параметров nnU-Net приступает к обучению модели нейронной сети. Контроль за процессом обучения также делегирован решению. Автоматически ведется контроль за переобучением (ситуация, когда модель слишком хорошо запомнила обучающий набор, но плохо обрабатывает новые случаи), лучшие модели сохраняются в настроенную директорию. Также nnU-Net может обучать сразу несколько разных моделей и при прогнозировании результата использовать ансамбль моделей. Завершающим этапом является постобработка результатов сегментации для улучшения ее качества (удаление мелких шумов/артефактов, соединение разрозненных областей).

### 3 Результаты

#### 3.1. Результаты предсказаний

Далее представлены попытки модели СППР nnU-Net корректно выполнить задачу сегментации, а также задачу классификации с разделением на отдельные зубы, согласно предоставленным лейблам. На следующих визуализациях представлены слева оригинальные снимки, справа предсказания модели. Эксперименты проводились на тестовой выборке КЛКТ-снимков (при раскраске отдельных зубов использовалась градиентная заливка). Другие результаты сегментации можно рассмотреть в приложениях работы.

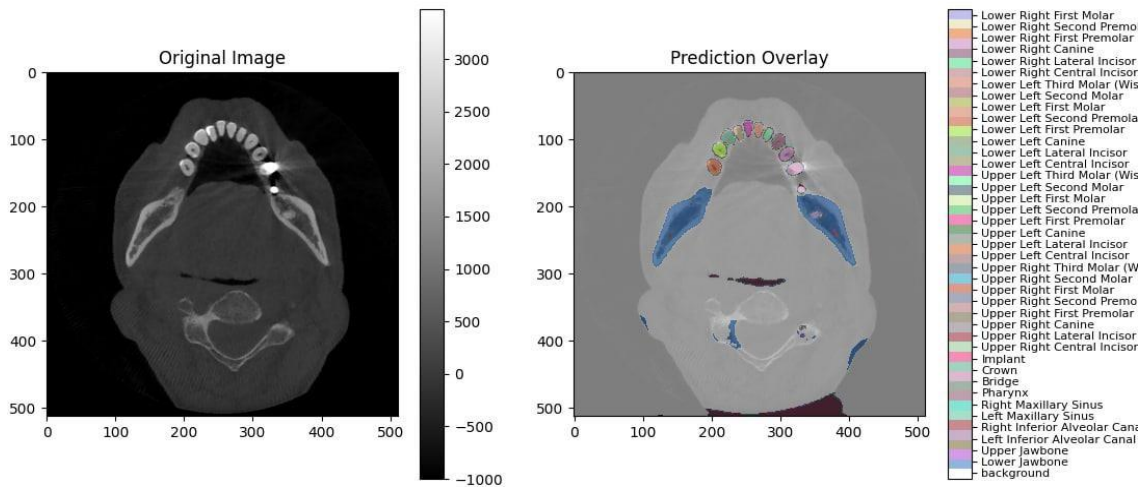


Рисунок 3 - Результат сегментации [1 снимок из тестового набора]

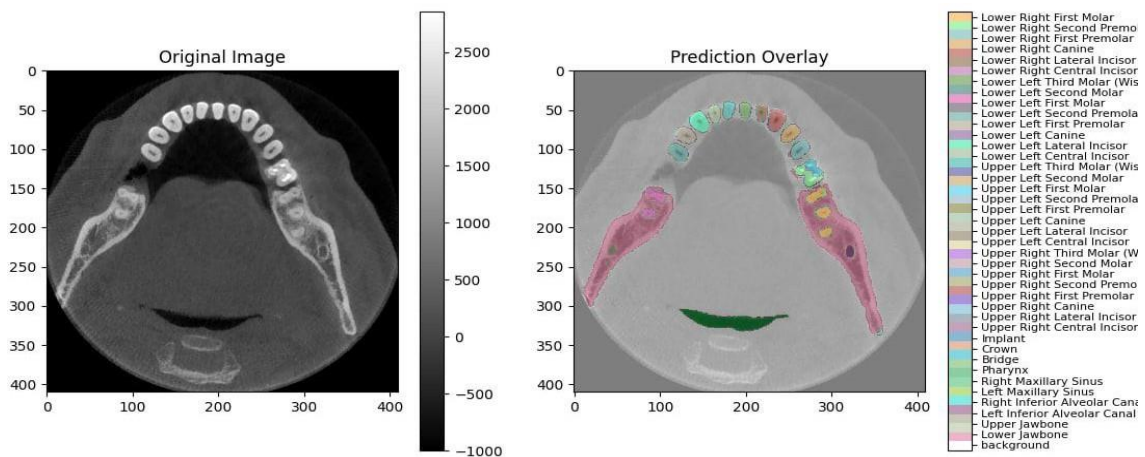


Рисунок 4 - Результат сегментации [5 снимок из тестового набора]






Рисунок 5 - Результат сегментации [7 снимок из тестового набора]




Рисунок 6 - Результат сегментации [9 снимок из тестового набора]

### 3.2. Метрики качества сегментации

Важно оценить, насколько хорошо модель справляется с поставленной задачей сегментации зубов (с разделением на классы) по КЛКТ-снимкам. Существуют различные метрики качества для оценки модели такие как Dice, Hausdorff distance 95, IoU (Intersection Over Union || коэффициент Жаккарда), существуют и другие.

В данном случае для оценки качества сегментации была выбрана метрика Dice (показатель сходства между сегментированной областью и истинным значением). Где FP – ложно положительный, FN – ложно отрицательный, TP – верно положительный (правильно сегментированные воксели зуба). Единичный Dice будет свидетельством идеального перекрытия.

$$Dice = \frac{2 * TP}{2 * TP + FP + FN} = \frac{2 * IoU}{1 + IoU}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$IoU = \frac{TP}{TP + FP + FN}$$

Таблица 1: Расчет метрик качества сегментации

Dice Coefficient: 0.7568567186726747  
Jaccard Index: 0.6088250083808247

	Precision	Recall	F1-score	Support
background	0.97	0.99	0.98	41931354
segmentation	0.84	0.69	0.76	4128046
accuracy	-	-	0.96	46059400
macro avg	0.90	0.84	0.87	46059400
weighted avg	0.96	0.96	0.96	46059400

Полученные результирующие метрики сегментации имеет смысл сравнить с существующими решениями других исследований. Проводить сравнение имеет смысл с результатами, полученными в статье, посвященной масштабированию nnU-Net фреймворка для сегментации КЛКТ-снимков [3]. Это особенно показательно, так как исследование проводилось с аналогичным моей работе набором данных. Путем модификаций nnU-Net авторы изменили размер патча, топологию сети и алгоритм аугментации данных, что позволило им добиться следующих метрик Dice 0.9253, HD95 18.472 на тестовом наборе данных.

Таблица 2: Сравнение результатов на тестовом наборе данных (n=50)

Model	Dice	HD95	Mean Rank
Scaling nnU-Net [3]	0.9253	18.472	4.6
Base nnU-Net	0.7568	-	-

Экспериментальные результаты данного исследования, показывают, что индивидуальная конфигурация nnU-Net (Scaling nnU-Net) в сочетании со стратегическими методами постобработки может достигать более высоких уровней точности в сравнении с базовым решением nnU-Net (Dice:  $0.76 < 0.93$ ).

## 4 Обсуждение

Стоит заметить, что для улучшения производительности модели и роста метрик качества сегментации и классификации следует задуматься о собственной конфигурации и доработки готового решения nnU-Net. СППР nnU-Net является решением с открытым исходным кодом, поэтому они открыты к вкладу со стороны других разработчиков и исследователей. Можно ввести ключевые модификации в размер патча, топологию сети, стратегии аугментации данных и добиться значительного прироста производительности. Этот подход способен решить уникальные проблемы, возникающие при работе с КЛКТ-снимками зубов, включая необходимость точной локализации и различения классов, которые имеют ключевое значение для клинической зубной практики (точечная диагностика зубных проблем, планирование стратегии лечения). Данный подход продемонстрирован в исследовании [3], где на практике удалось вырастить метрики Dice, Hausdorff distance 95 и другие путем масштабирования фреймворка nnU-Net.

## 5 Заключение

В этой научно-исследовательской работе был разработан и апробирован подход глубокого обучения с использованием фреймворка nnU-Net для мультиклассовой сегментации на снимках конусно-лучевой компьютерной томографии (КЛКТ). СППР nnU-Net совершает много ручной работы под капотом, комбинирует U-Net архитектуры нейронных сетей и настраивает их под входящий поток данных. Внутри системы заложен самообучающийся генетический алгоритм, пользователю нет нужды задумываться о подборе гиперпараметров, скорости обучения, аугментации данных. Таким образом в первую очередь была решена задача сегментации зубов на КЛКТ-снимках, после чего была выполнена классификация зубов с разделением на отдельные зубы, согласно 42 предложенным классам зубов. Для оценки качества сегментации предлагаемого решения были выбраны метрики Dice-коэффициент, который достиг значения в 0.76 и коэффициент Жаккарда в 0.61. После выполнения задачи сегментации было необходимо оценить качество разделения зубов согласно лейблам, для этого была посчитана Dice-метрика под каждый лейбл, результат представлен в работе и репозитории.

Также возможно улучшение производительности модели, путем масштабирования фреймворка nnU-Net, есть исследования, описывающие данные возможности.

Предлагаемое решение задачи сегментации по КЛКТ-снимкам может найти свое применение в области цифровизации стоматологических процессов диагностики, планирования лечения, а также может помочь снизить клиническую нагрузку.

## Ссылки

1. M. Chung, M. Lee, J. Hong, S. Park, J. Lee, J. Lee, I.-H. Yang, J. Lee, Y.-G. Shin, Pose-aware instance segmentation framework from cone beam CT images for tooth segmentation, Comput. Biol. Med. 120 (2020), 103720, <https://doi.org/10.1016/j.cbm.2020.103720>.
2. Y. Wang, S. Liu, G. Wang, Y. Liu, Accurate tooth segmentation with improved hybrid active contour model, Phys. Med. Biol. 64 (2018), 015012, <https://doi.org/10.1088/1361-6560/aaf441>.
3. Scaling nnU-Net for CBCT Segmentation C. Ulrich, F. Isensee, T. Wald, M. Zenk, M. Baumgartner, and K. H. Maier-Hein. Multitalent: A multi-dataset approach to medical image segmentation. In International Conference on Medical Image Computing and Computer-Assisted Intervention, pages 648–658. Springer, 2023.
4. Z. Cui, C. Li, W. Wang, Toothnet: automatic tooth instance segmentation and identification from cone beam ct images, in: Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit. 2019-June, 2019, pp. 6361–6370, <https://doi.org/10.1109/CVPR.2019.00653>.
5. Zhang F. et al. A comparison of U-Net series for teeth segmentation in CBCT images // Medical Imaging 2024: Image Processing. – SPIE, 2024. – T. 12926. – C. 810-815.
6. H. Wang, J. Minnema, K.J. Batenburg, T. Forouzanfar, F.J. Hu, G. Wu, Multiclass CBCT image segmentation for orthodontics with deep learning, J. Dent. Res. 100 (2021) 943–949, <https://doi.org/10.1177/00220345211005338>.
7. nnU-Net репозиторий: <https://github.com/MIC-DKFZ/nnUNet>
8. Репозиторий с кодом модели: <https://github.com/ima tyushov/ct-teeth-segmentation>

## Приложения

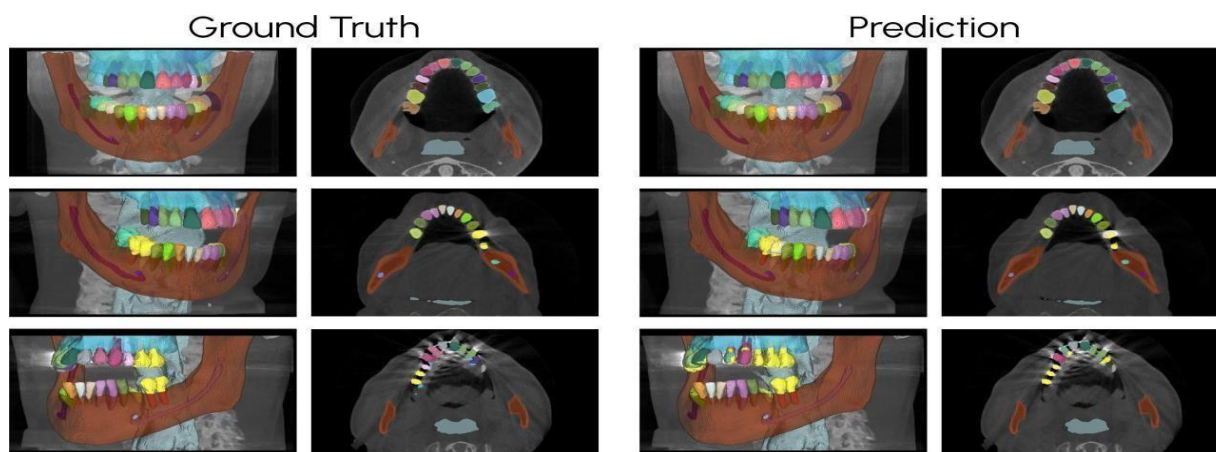


Рисунок 7 - Прогноз получен на тестовой выборке. Большинство случаев прогнозируются точно, и все зубы правильно классифицированы (сверху). Небольшие ошибки включают неправильную классификацию зубов или несоответствия между коронками и зубами (в середине) [3]

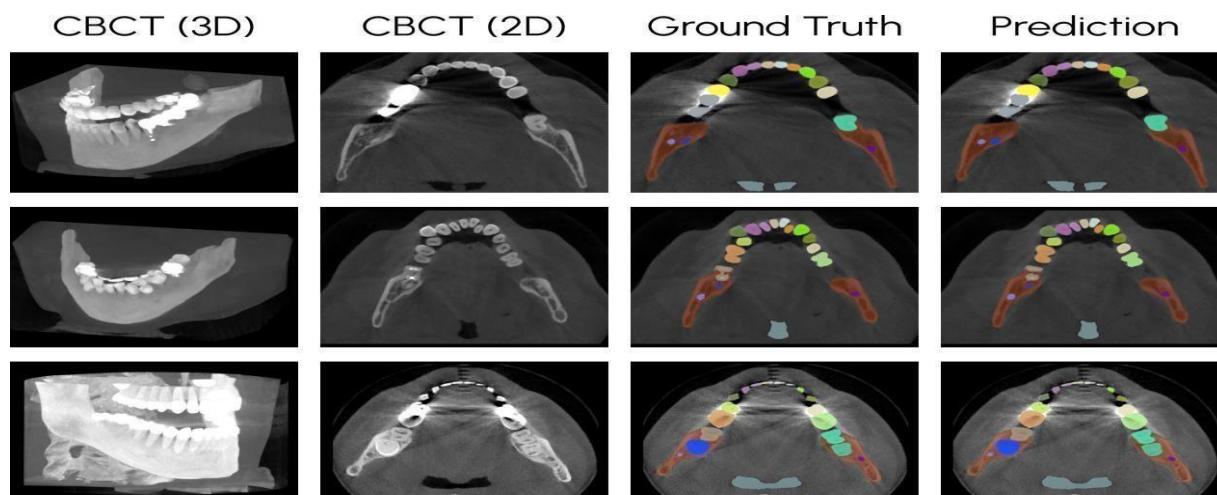


Рисунок 8 - Иллюстрация работы при сложных кейсах (артефакты, шумы, анатомические выбросы) [3]



```

"labels": {
  "background": 0, "Lower Jawbone": 1,
  "Upper Jawbone": 2, "Left Inferior Alveolar Canal": 3,
  "Right Inferior Alveolar Canal": 4, "Left Maxillary Sinus": 5,
  "Right Maxillary Sinus": 6, "Pharynx": 7,
  "Bridge": 8, "Crown": 9,
  "Implant": 10, "Upper Right Central Incisor": 11,
  "Upper Right Lateral Incisor": 12, "Upper Right Canine": 13,
  "Upper Right First Premolar": 14, "Upper Right Second Premolar": 15,
  "Upper Right First Molar": 16, "Upper Right Second Molar": 17,
  "Upper Right Third Molar (Wisdom Tooth)": 18, "Upper Left Central Incisor": 19,
  "Upper Left Lateral Incisor": 20, "Upper Left Canine": 21,
  "Upper Left First Premolar": 22, "Upper Left Second Premolar": 23,
  "Upper Left First Molar": 24, "Upper Left Second Molar": 25,
  "Upper Left Third Molar (Wisdom Tooth)": 26, "Lower Left Central Incisor": 27,
  "Lower Left Lateral Incisor": 28, "Lower Left Canine": 29,
  "Lower Left First Premolar": 30, "Lower Left Second Premolar": 31,
  "Lower Left First Molar": 32, "Lower Left Second Molar": 33,
  "Lower Left Third Molar (Wisdom Tooth)": 34, "Lower Right Central Incisor": 35,
  "Lower Right Lateral Incisor": 36, "Lower Right Canine": 37,
  "Lower Right First Premolar": 38, "Lower Right Second Premolar": 39,
  "Lower Right First Molar": 40, "Lower Right Second Molar": 41,
  "Lower Right Third Molar (Wisdom Tooth)": 42
},

```

Рисунок 9 - JSON-файл с классами для предсказания

```

(nn_UNet_v2) F:\Work\nnUnet_v2>nnUnetv2_plan_and_preprocess -d 112 --verify_dataset_integrity
Fingerprint extraction...
Dataset112_ToothFairy2
Using <class 'nnunetv2.imageio.simpleitk_reader_writer.SimpleITKIO'> as reader/writer

```

```

(nn_UNet_v2) F:\Work\nnUnet_v2>nnUnetv2_plan_and_preprocess -d 112 --verify_dataset_integrity
Fingerprint extraction...
Dataset112_ToothFairy2
Using <class 'nnunetv2.imageio.simpleitk_reader_writer.SimpleITKIO'> as reader/writer

#####
verify_dataset_integrity Done.
If you didn't see any error messages then your dataset is most likely OK!
#####

Using <class 'nnunetv2.imageio.simpleitk_reader_writer.SimpleITKIO'> as reader/writer
4% | 21/480 [01:33<18:49, 2.46s/it]

```

Рисунок 10 - Создания плана обучения модели nnU-Net












Рисунок 15 - Визуализация кривых обучения модели

```
C:\Users\ziase\AppData\Local\Programs\Python\Python310\python.exe F:\Work\Med_KT_teeth\main.py
Dice score for label 0: 0.9874694148075648
Dice score for label 1: 0.8111399746339547
Dice score for label 2: 0.8516127526334568
Dice score for label 3: 0.5155315586235177
Dice score for label 4: 0.48117737109456543
Dice score for label 5: 0.0
Dice score for label 6: 0.1910734751050554
Dice score for label 7: 0.6288517342680447
Dice score for label 8: 0.30433676713722496
Dice score for label 9: 0.46407072533654814
Dice score for label 10: 0.0
Dice score for label 11: 0.7938247232881575
Dice score for label 12: 0.34028948439225715
Dice score for label 13: 0.5898297961756671
Dice score for label 14: 0.6138283006257974
Dice score for label 15: 0.5458089668615984
Dice score for label 16: 0.0
Dice score for label 17: 0.0
Dice score for label 18: 0.0
Dice score for label 19: 0.0
Dice score for label 20: 0.0
Dice score for label 21: 0.0
Dice score for label 22: 0.0
Dice score for label 23: 0.0
Dice score for label 24: 0.0
Dice score for label 25: 0.0
Dice score for label 26: 0.0
Dice score for label 27: 0.0
Dice score for label 28: 0.0
Dice score for label 29: 0.0
Dice score for label 30: 0.0
Dice score for label 31: 0.0
Dice score for label 32: 0.0
Dice score for label 33: 0.0
Dice score for label 34: 0.0
Dice score for label 35: 0.0
Dice score for label 36: 0.0
Dice score for label 37: 0.0
Dice score for label 38: 0.0
Dice score for label 39: 0.0
Dice score for label 40: 0.0
Dice score for label 41: 0.0
Dice score for label 42: 0.0
Dice score for label 43: 0.0
Dice score for label 44: 0.0
Dice score for label 45: 0.0
Dice score for label 47: 0.0

Process finished with exit code 0
```

Рисунок 16 - Метрика качества Dice, посчитанная под каждый лейбл [1 снимок]

```
C:\Users\ziaze\AppData\Local\Programs\Python\Python310\python.exe F:\Work\Med_KT_teeth\main.py
Dice score for label 0: 0.9948853866918814
Dice score for label 1: 0.9720148749112955
Dice score for label 2: 0.8593061263982432
Dice score for label 3: 0.7646090534979424
Dice score for label 4: 0.8242616148932685
Dice score for label 5: 0.00025917646677681665
Dice score for label 6: 0.5596536624203822
Dice score for label 7: 0.9310503030284318
Dice score for label 8: 0.0027562107024645937
Dice score for label 9: 0.6623764724484149
Dice score for label 10: 0.0
Dice score for label 11: 0.5359767397277782
Dice score for label 12: 0.2544569585149131
Dice score for label 13: 0.7646265412018598
Dice score for label 14: 0.5098150782361308
Dice score for label 15: 0.46206746635574963
Dice score for label 16: 0.0
Dice score for label 17: 0.0
Dice score for label 18: 0.30912025827280065
Dice score for label 19: 0.0
Dice score for label 20: 0.0
Dice score for label 21: 0.0
Dice score for label 22: 0.0
Dice score for label 23: 0.0
Dice score for label 24: 0.0
Dice score for label 25: 0.0
Dice score for label 26: 5.164355617527823e-05
Dice score for label 27: 0.0
Dice score for label 28: 0.0
Dice score for label 29: 0.0
Dice score for label 30: 0.0
Dice score for label 31: 0.0
Dice score for label 32: 0.0
Dice score for label 33: 0.0
Dice score for label 34: 0.0
Dice score for label 35: 0.0
Dice score for label 36: 0.0
Dice score for label 37: 0.0
Dice score for label 38: 0.0
Dice score for label 39: 0.0
Dice score for label 40: 0.0
Dice score for label 41: 0.0
Dice score for label 42: 0.0
Dice score for label 43: 0.0
Dice score for label 44: 0.0
Dice score for label 45: 0.0
Dice score for label 46: 0.0
Dice score for label 47: 0.0
Dice score for label 48: 0.0
```

Рисунок 17 - Метрика качества Dice, посчитанная под каждый лейбл [5 снимок]

```
C:\Users\ziaze\AppData\Local\Programs\Python\Python310\python.exe F:\Work\Med_KT_teeth\main.py
Dice score for label 0: 0.9925724076239312
Dice score for label 1: 0.9307054445799795
Dice score for label 2: 0.7440868061419068
Dice score for label 3: 0.3894009882393735
Dice score for label 4: 0.3699974084632187
Dice score for label 5: 0.014739652870493992
Dice score for label 6: 0.39048685963424973
Dice score for label 7: 0.8726775178991147
Dice score for label 8: 0.0
Dice score for label 9: 0.0
Dice score for label 10: 0.0
Dice score for label 11: 0.7009046684304856
Dice score for label 12: 0.0
Dice score for label 13: 0.3204774205041418
Dice score for label 14: 0.2623562536042607
Dice score for label 15: 0.7568382511307344
Dice score for label 16: 0.888379263827327
Dice score for label 17: 0.8368883312421581
Dice score for label 18: 0.0
Dice score for label 19: 0.0
Dice score for label 20: 0.0
Dice score for label 21: 0.0
Dice score for label 22: 0.0
Dice score for label 23: 0.0
Dice score for label 24: 0.0
Dice score for label 25: 0.0
Dice score for label 26: 0.0
Dice score for label 27: 0.0
Dice score for label 28: 0.0
Dice score for label 29: 0.0
Dice score for label 30: 0.0
Dice score for label 31: 0.0
Dice score for label 32: 0.0
Dice score for label 33: 0.0
Dice score for label 34: 0.0
Dice score for label 35: 0.0
Dice score for label 36: 0.0
Dice score for label 37: 0.0
Dice score for label 38: 0.0
Dice score for label 39: 0.0
Dice score for label 40: 0.0
Dice score for label 41: 0.0
Dice score for label 42: 0.0
Dice score for label 43: 0.0
Dice score for label 44: 0.0
Dice score for label 45: 0.0
Dice score for label 46: 0.0
```

Рисунок 18 - Метрика качества Dice, посчитанная под каждый лейбл [7 снимок]



```
C:\Users\ziaze\AppData\Local\Programs\Python\Python310\python.exe F:\Work\Med_KT_teeth\main.py
Dice score for label 0: 0.9961840976046625
Dice score for label 1: 0.9589914802277264
Dice score for label 2: 0.9103187915194706
Dice score for label 3: 0.7129022180568573
Dice score for label 4: 0.6823046053888783
Dice score for label 5: 0.09414877061935885
Dice score for label 6: 0.5014472965592572
Dice score for label 7: 0.9696247170438924
Dice score for label 8: 0.0
Dice score for label 9: 0.0
Dice score for label 11: 0.6190118354311478
Dice score for label 12: 0.0006333122229259025
Dice score for label 13: 0.5573937975809907
Dice score for label 14: 0.07441519702757862
Dice score for label 15: 0.27517829187684817
Dice score for label 16: 0.03994511956095649
Dice score for label 17: 0.35428991172265434
Dice score for label 18: 0.09918706180911006
Dice score for label 19: 0.0
Dice score for label 20: 0.0
Dice score for label 21: 0.0
Dice score for label 22: 0.0
Dice score for label 23: 0.0
Dice score for label 24: 0.0
Dice score for label 25: 0.0
Dice score for label 26: 0.0
Dice score for label 27: 0.0
Dice score for label 28: 0.0
Dice score for label 29: 0.0
Dice score for label 30: 0.0
Dice score for label 31: 0.0
Dice score for label 32: 0.0
Dice score for label 33: 0.0
Dice score for label 34: 0.0
Dice score for label 35: 0.0
Dice score for label 36: 0.0
Dice score for label 37: 0.0
Dice score for label 38: 0.0
Dice score for label 39: 0.0
Dice score for label 40: 0.0
Dice score for label 41: 0.0
Dice score for label 42: 0.0
Dice score for label 43: 0.0
Dice score for label 44: 0.0
Dice score for label 45: 0.0
Dice score for label 46: 0.0
Dice score for label 47: 0.0
Dice score for label 48: 0.0
```

Рисунок 19 - Метрика качества Dice, посчитанная под каждый лейбл [9 снимок]